



Универзитет „Св. Кирил и Методиј“ во Скопје  
**ФАКУЛТЕТ ЗА ИНФОРМАТИЧКИ НАУКИ И  
КОМПЈУТЕРСКО ИНЖЕНЕРСТВО**

Предмет

**Вовед во препознавање на облици**

Тема

**Experimental approach to human activity recognition**

Студент

Душица Јанковиќ

161509

Август 2020

# Содржина

Вовед .....	3
Податоци .....	4
Дополнителни вредности .....	5
Временски прозорци.....	6
Интерпретација на податоците .....	7
Временски домен.....	7
Авторегресија .....	8
Фреквентен домен .....	8
Wavelets .....	8
Збирен вектор со карактеристики .....	9
Експерименти и резултати.....	10
1 Невронски мрежи и временски серии.....	10
Архитектури на неврронски мрежи .....	10
Резултати .....	12
2 Конволуциска неврронска мрежа и wavelet images .....	13
3 Класификатори од алатката Weka.....	15
Заклучок.....	16
Github repository .....	16
Користена литература .....	16


## Вовед

Препознавање на човечки активности со користење на сензорски системи има широка примена во здравство, атлетика, рехабилитација и надгледување на стари лица. Оваа област доаѓа со низа предизвици кога станува збор за мерење на активностите, нивна репрезентација и интерпретација, а и потоа соодветна класификација со некаков систем за препознавање. Некои од проблемите на кои се наидува се бучава во медиумот, комплексност на пресметките, брзина на класификациите, цена на опремата итн. Постојат различни експериментални пристапи кои вклучуваат различни типови на статички или wearable групации на сензори. Техниките од машинско учење како користење на класификатори и невронски мрежи со различна комплексност постигнуваат задоволителни резултати.

Овој проект претрпавува експериментален пристап на класификацискиот проблем со човечки активности. Во него се анализираат различни начини за толкување на податоците и извлекување на карактеристики од нив, и различни пристапи за класификација. Податоците содржат сигнали измерени од сензорски систем составен од пасивни инфрацрвени сензори и микробранови радар сензори. Од интерес се сигналите во временски и фреквентен домен. Податоците соодветно се процесираат со цел да се извлечат временски серии, фреквентни компоненти и вејвлет коефициенти. Резултатите се користат како серии, но и се експериментира и со нивни агрегации и извлекување на дополнителни особини. Имплементацијата е во python, но освен тоа, вклучени се експерименти со алатката WEKA.

## Податоци


Податоците се сензорски измерени вредности лабелирани со активната која ја мерат. Податочното множество е добиено со експеримент во кој се мониторираат човечки активности во една просторија. Експериментот се одвивал на 21.06, 26.06, 27.06 и 03.06, со тoтaлнo времетраење од 3 часа, 57 минути и 16 милисекунди. Со користење на амбиентални сензори се формирани три модули за прибирање податоци. Секој модул е составен од еден пасивен инфрацрвен сензор (пир) и еден микробранов радар (мр) сензор. Модулите се поставени на сидот лево од влезот на просторијата (лев модул), на сидот поставен бочно на левиот сид (десен модул) и на плафонот (горен модул). Самата просторија е опремена со едноставен мебел потребен само за експериментот и соодветните активности.



Експериментот опфаќа 9 активности видливи во табелата придружени со соодветната лабела како која се јавуваат во податоците. Активностите во текот на мерењата се одвиваат по случаен редослед, но се обрнува внимание да не се повтори истата активност два пати последователно.

Лабела	Активност
SB (sitting on the bed)	Седење на кревет
ST (sitting on the table)	Седење на маса
WO (walking out of the room)	Излегување од просторијата
WI (walking into the room)	Влегување во просторијата
WA (walking around the room)	Движење низ просторијата
ET (eating at the table)	Јадење на маса
LB (laying on the bed)	Лежење на кревет
NA (no activity)	Нема субјект во просторијата
SD (standing in one place)	Стојење во место

Активностите не се јавуваат во подеднаков број низ податочното множество. Најголем број примероци се лабелирани WA додека во најмал број се јавува активност SD.



Бидејќи активностите се јавуваат по случаен редослед, некои активности воопшто не се јавуваат едно-по-друго додека други често се слеани. Ова е важно за подоцна, кога податоците ќе ги делиме на прозорци со определена големина бидејќи во тие прозорци ќе има и онакви кои содржат мерења од две активности. На следната листа се прикажани активностите кои најчесто следат по дадена активност:

- SB: WA (91), LB (71), SD (8)
- ST: WA (41), ET (38), SD (8)
- WO: WI (3), NA (69), SD (1)
- WI: SB (1), WO (1), WA (52), SD (17)
- WA: SB (93), WO (70), ET (38), LB (7) SD (29)
- ET: ST (7), WA (64) SD (12)
- LB: SB (65), WA (9), SD (4)
- NA: ST (1), WI (68)
- SD: ST (10), WO (2), WA (50), ET (7)

Модулите регистрираат мерења на секои 0.04 секунди, односно се добиваат 25 мерења за секоја секунда. Бидејќи секој модул има два сензори, за секој од 25-те временски моменти постојат по 6 мерења – се добива вектор со сензорски мерења со должина 6 (*initial\_moment\_vector*). Левиот модул, десниот и горниот модул оддаваат мерења конкатенирани во вектор во следниот редослед: радар (лево), пир (лево), радар (десно), пир (десно), радар (горе), пир (горе). За време на експериментот се измерени вкупно 355 504 вакви вектори и секој е соодветно лабелиран со активноста која се случувала во тој временски момент.

Лев модул	Десен модул	Горен модул	Активност
Микробранов радар сензор	Микробранов радар сензор	Микробранов радар сензор	
Пасивен инфрацрвен сензор	Пасивен инфрацрвен сензор	Пасивен инфрацрвен сензор	
607, 533	650, 554	397, 560	WI
578, 542	619, 568	401, 566	WI
547, 571	556, 564	410, 554	WI
512, 538	540, 552	455, 563	WI
⋮	⋮	⋮	

## Дополнителни вредности

За секој временски момент и мерењата кои се случуваат во него може да се пресметаат дополнителни вредности и да се прошири податочното множество (се проширува *initial\_moment\_vector*). Трите модули во просторијата се поставени на соодветни локации така што формираат координатен систем. Левиот, десниот и горниот модул се оските X, Y и Z соодветно. Ова е од голема корист бидејќи тоа се користи за да може да се пресметаат останатите карактеристики. Секој модул има два типа на сензори, секој тип припаѓа во хомоген координатен систем, па затоа се формираат два координатни системи. За секој посебно се вршат пресметките по истите формули. Во прилог се пресметките за дополнителните вредности:

- Должина на вектор определен со мерењата за трите оски
  - $length_{MR} = \sqrt{X_{MR}^2 + Y_{MR}^2 + Z_{MR}^2}$
  - $length_{PIR} = \sqrt{X_{PIR}^2 + Y_{PIR}^2 + Z_{PIR}^2}$
- Ориентациски агол  $\alpha$  на векторот со X оската

- $\alpha_{MR} = \arccos(\frac{X_{MR}}{length_{MR}})$
- $\alpha_{PIR} = \arccos(\frac{X_{PIR}}{length_{PIR}})$
- Ориентациски агол  $\beta$  на векторот со Y оската
  - $\beta_{MR} = \arccos(\frac{Y_{MR}}{length_{MR}})$
  - $\beta_{PIR} = \arccos(\frac{Y_{PIR}}{length_{PIR}})$
- Ориентациски агол  $\gamma$  на векторот со Z оската
  - $\gamma_{MR} = \arccos(\frac{Z_{MR}}{length_{MR}})$
  - $\gamma_{PIR} = \arccos(\frac{Z_{PIR}}{length_{PIR}})$

Со ова на initial\_moment\_vector се додаваат по четири нови вредности за сензорот пир и сензорот мр. Резултатот е вектор со големина 14 (extended\_moment\_vector).

MR left   PIR left   MR right   PIR right   MR up   PIR up   MR vector length   PIR vector length   MR alpha   MR beta   MR gamma   PIR alpha   PIR beta   PIR gamma

436, 104, 695, 998, 543, 48, 983.855, 1004.552, 1.112, 0.786, 0.986, 1.467, 0.114, 1.523

## Временски прозорци

Податоците сами по себе се листа од изолирани вектори кои се однесуваат на одредени временски моменти. Такви индивидуални 'snapshots' не се многу корисни кога станува збор за препознавање активност која се одвива значително подолго од само еден временски момент (најкраќката е 49 мерења). Затоа потребно е временските моменти да се групираат со своите последователни со помош на техниката на лизгачки прозорец. Со ова, во секој прозорец би бил опфатен некој дел од времетраењето на некоја активност и од истиот би можело полесно да се извлечат некои скриени законитости за таа активност.

Во пракса често се користат лизгачки прозорци кои се поклопуваат 50% од својата должина. Во овој проект се експериментираше со прозорци со должина од 1 секунди се до 10 секунди. За real-time апликации предизвикот е користење на кратки прозорци кои сепак би нуделе доволно информации за точно препознавање на активността.

На следната слика е прикажана трансформацијата од листа од 355 504 вектори во податочното множество до листа од прозорци: групации на векторите. Овој конкретен пример користи прозорци со должина 1 секунда кои содржат 25 вектори. Преклопувањето е  $25 * 50\% \sim 13$ .

1496	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1497	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1498	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1499	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1500	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1501	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1502	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1503	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1504	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1505	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1506	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1507	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1508	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1509	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1510	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1511	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1512	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1513	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1514	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1515	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1516	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1517	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1518	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1519	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1520	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1521	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1522	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1523	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1524	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1525	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1526	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1527	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1528	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1529	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1530	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1531	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1532	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1533	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1534	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1535	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1536	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1537	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1538	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1539	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1540	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1541	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1542	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1543	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1544	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1545	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1546	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1547	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1548	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1549	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1550	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1551	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1552	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1553	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1554	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1555	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1556	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1557	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1558	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1559	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1560	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1561	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1562	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1563	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1564	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1565	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1566	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1567	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1568	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1569	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1570	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1571	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1572	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1573	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1574	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1575	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1576	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1577	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1578	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1579	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1580	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1581	104	585	998	428	543	983.854	1004.551	1.111	0.785	0.985	1.466	0.113	1.522	-
1582	104	585	998	428	543	983.854	1004.551	1.111</						

Освен оваа трансформација, вредностите се дополнително стандардизирани со пресметување на z score за секоја карактеристика ( $z_i = \frac{x_i - \text{mean}}{\text{std}}$ ). Средна вредност и стандардна девијација се пресметуваат за секоја карактеристика посебно, и тоа само со податоците од тренинг множеството. Потоа, тренинг и тест множествата се стандардизираат со истите вредности. Финално, резултатот е видлив со пример прозорецот на следната слика.

```
[-0.827, -1.762, 0.603, 1.675, -0.185, -2.68, -0.197, -0.063, 0.822, -0.928, 0.145, 1.864, -3.251, 2.559]
[-1.542, -1.75, -0.331, 1.675, 0.389, -2.826, -0.838, -0.066, 1.282, -0.087, -1.131, 1.852, -3.273, 2.687]
[-0.849, -1.75, 0.326, 1.679, -0.495, -2.877, -0.61, -0.062, 0.632, -0.879, 0.252, 1.852, -3.278, 2.731]
[-0.062, -1.766, -0.141, 1.679, -1.338, -2.882, -0.999, -0.064, -0.596, -0.498, 1.054, 1.868, -3.293, 2.735]
[0.696, -1.766, -1.155, 1.679, -1.25, -2.882, -1.139, -0.064, -1.866, 0.874, 0.869, 1.868, -3.293, 2.735]
[1.723, -1.766, -0.844, 1.679, -0.717, -2.882, 0.016, -0.064, -1.993, 1.028, 1.868, -3.293, 2.735]
[0.28, -1.766, -0.463, 1.679, -0.043, -2.897, -0.352, -0.064, -0.492, 0.4, -0.128, 1.868, -3.294, 2.749]
[-0.39, -1.766, -0.227, 1.683, 0.342, -2.882, -0.312, -0.06, 0.298, 0.123, -0.58, 1.868, -3.294, 2.736]
[0.397, -1.77, 0.269, 1.573, -0.036, -2.882, 0.214, -0.183, -0.22, -0.172, 0.228, 1.86, -3.286, 2.734]
[0.506, -1.77, 0.741, 0.944, -0.34, -2.897, 0.474, -0.882, -0.168, -0.589, 0.682, 1.773, -3.206, 2.743]
[0.018, -1.75, 1.012, 0.451, -0.319, -2.882, 0.457, -1.424, 0.309, -0.955, 0.653, 1.646, -3.088, 2.719]
[-0.361, -1.766, 1.035, 0.027, -0.225, -2.907, 0.349, -1.895, 0.622, -1.076, 0.502, 1.55, -3.0, 2.748]
[-0.259, -1.766, 0.949, -0.341, -0.124, -2.913, 0.374, -2.298, 0.535, -0.937, 0.41, 1.401, -2.862, 2.752]
[0.026, -1.766, 0.834, -0.576, 0.099, -2.882, 0.506, -2.554, 0.377, -0.683, 0.249, 1.27, -2.739, 2.686]
[0.288, -1.766, 0.736, -0.723, 0.348, -2.882, 0.72, -2.713, 0.189, -0.416, 0.11, 1.167, -2.643, 2.677]
[0.288, -1.766, 0.978, -0.845, 0.888, -2.913, 1.218, -2.844, 0.436, -0.385, -0.151, 1.065, -2.552, 2.745]
[0.266, -1.766, 1.093, -0.886, 1.09, -2.882, 1.418, -2.888, 0.544, -0.394, -0.235, 1.026, -2.512, 2.666]
[0.28, -1.766, 0.989, -0.894, 1.158, -2.887, 1.388, -2.896, 0.519, -0.299, -0.319, 1.019, -2.506, 2.679]
[0.185, -1.766, 0.476, -0.833, 0.881, -2.882, 0.798, -2.831, 0.326, -0.068, -0.403, 1.076, -2.558, 2.67]
[-0.383, -1.75, -0.1, -0.784, 0.578, -2.877, -0.067, -2.773, 0.43, 0.111, -0.681, 1.075, -2.557, 2.662]
[-0.689, -1.762, -0.446, -0.629, 0.369, -2.842, -0.581, -2.609, 0.469, 0.243, -0.849, 1.226, -2.689, 2.596]
[-0.565, -1.766, -0.544, -0.443, 0.24, -2.644, -0.673, -2.396, 0.272, 0.317, -0.755, 1.355, -2.702, 2.234]
[-0.157, -1.762, -0.365, -0.295, 0.24, -2.426, -0.353, -2.206, 0.014, 0.275, -0.483, 1.431, -2.587, 1.897]
[0.703, -1.762, -0.158, -0.087, 0.247, -2.153, 0.257, -1.931, -0.521, 0.361, -0.058, 1.531, -2.429, 1.564]
[0.812, -1.762, -0.221, 0.0, 0.119, -1.94, 0.206, -1.786, -0.679, 0.408, 0.053, 1.575, -2.262, 1.31]
```

## Интерпретација на податоците

### Временски домен

Со досегашните трансформации, векторите во прозорците се однесуваат на последователни временски моменти, а содржат мерења извршени од различни сензори истовремено. Во пракса од поголем интерес се сериите од мерења разгледани за секој сензор посебно со текот на времето. Со транспонирање на секој прозорец, се добиваат временски серии за секој сензор. Всушност, се добиваат мерења кои опишуваат сигнали од временски домен.

```
[0.827, -1.762, 0.603, 1.675, -0.185, -2.68, -0.197, -0.063, 0.822, -0.928, 0.145, 1.864, -3.251, 2.559]
[-1.542, -1.75, -0.331, 1.675, 0.389, -2.826, -0.838, -0.066, 1.282, -0.087, -1.131, 1.852, -3.273, 2.687]
[-0.849, -1.75, 0.326, 1.679, -0.495, -2.877, -0.61, -0.062, 0.632, -0.879, 0.252, 1.852, -3.278, 2.731]
[-0.062, -1.766, -0.141, 1.679, -1.338, -2.882, -0.999, -0.064, -0.596, -0.498, 1.054, 1.868, -3.293, 2.735]
[0.696, -1.766, -1.155, 1.679, -1.25, -2.882, -1.139, -0.064, -1.866, 0.874, 0.869, 1.868, -3.293, 2.735]
[1.723, -1.766, -0.844, 1.679, -0.717, -2.882, 0.016, -0.064, -1.993, 1.028, 1.868, -3.293, 2.735]
[0.28, -1.766, -0.463, 1.679, -0.043, -2.897, -0.352, -0.064, -0.492, 0.4, -0.128, 1.868, -3.294, 2.749]
[-0.39, -1.766, -0.227, 1.683, 0.342, -2.882, -0.312, -0.06, 0.298, 0.123, -0.58, 1.868, -3.294, 2.736]
[0.397, -1.77, 0.269, 1.573, -0.036, -2.882, 0.214, -0.183, -0.22, -0.172, 0.228, 1.86, -3.286, 2.734]
[0.506, -1.77, 0.741, 0.944, -0.34, -2.897, 0.474, -0.882, -0.168, -0.589, 0.682, 1.773, -3.206, 2.743]
[0.018, -1.75, 1.012, 0.451, -0.319, -2.882, 0.457, -1.424, 0.309, -0.955, 0.653, 1.646, -3.088, 2.719]
[-0.361, -1.766, 1.035, 0.027, -0.225, -2.907, 0.349, -1.895, 0.622, -1.076, 0.502, 1.55, -3.0, 2.748]
[-0.259, -1.766, 0.949, -0.341, -0.124, -2.913, 0.374, -2.298, 0.535, -0.937, 0.41, 1.401, -2.862, 2.752]
[0.026, -1.766, 0.834, -0.576, 0.099, -2.882, 0.506, -2.554, 0.377, -0.683, 0.249, 1.27, -2.739, 2.686]
[0.288, -1.766, 0.736, -0.723, 0.348, -2.882, 0.72, -2.713, 0.189, -0.416, 0.11, 1.167, -2.643, 2.677]
[0.288, -1.766, 0.978, -0.845, 0.888, -2.913, 1.218, -2.844, 0.436, -0.385, -0.151, 1.065, -2.552, 2.745]
[0.266, -1.766, 1.093, -0.886, 1.09, -2.882, 1.418, -2.888, 0.544, -0.394, -0.235, 1.026, -2.512, 2.666]
[0.28, -1.766, 0.989, -0.894, 1.158, -2.887, 1.388, -2.896, 0.519, -0.299, -0.319, 1.019, -2.506, 2.679]
[0.185, -1.766, 0.476, -0.833, 0.881, -2.882, 0.798, -2.831, 0.326, -0.068, -0.403, 1.076, -2.558, 2.67]
[-0.383, -1.75, -0.1, -0.784, 0.578, -2.877, -0.067, -2.773, 0.43, 0.111, -0.681, 1.075, -2.557, 2.662]
[-0.689, -1.762, -0.446, -0.629, 0.369, -2.842, -0.581, -2.609, 0.469, 0.243, -0.849, 1.226, -2.689, 2.596]
[-0.565, -1.766, -0.544, -0.443, 0.24, -2.644, -0.673, -2.396, 0.272, 0.317, -0.755, 1.355, -2.702, 2.234]
[-0.157, -1.762, -0.365, -0.295, 0.24, -2.426, -0.353, -2.206, 0.014, 0.275, -0.483, 1.431, -2.587, 1.897]
[0.703, -1.762, -0.158, -0.087, 0.247, -2.153, 0.257, -1.931, -0.521, 0.361, -0.058, 1.531, -2.429, 1.564]
[0.812, -1.762, -0.221, 0.0, 0.119, -1.94, 0.206, -1.786, -0.679, 0.408, 0.053, 1.575, -2.262, 1.31]
```



Timeseries:

```
MR L [-0.827, -1.542, -0.849, -0.062, 0.696, 1.723, 0.28, -0.39, 0.397, 0.506, 0.018, -0.361, -0.259, -0.026, 0.288, 0.288, 0.266, 0.28, 0.185, -0.383, -0.689, -0.565, -0.157, 0.703, 0.812]
PIR L [-1.762, -1.75, -1.75, -1.766, -1.766, -1.766, -1.766, -1.77, -1.77, -1.75, -1.766, -1.766, -1.766, -1.766, -1.766, -1.766, -1.766, -1.766, -1.766, -1.762, -1.762, -1.762]
MR R [0.603, 0.331, 0.326, -0.141, -1.155, -0.844, -0.463, -0.227, 0.269, 0.741, 1.012, 1.035, 0.949, 0.834, 0.736, 0.978, 1.093, 0.889, 0.476, -0.1, -0.446, -0.544, -0.365, -0.158, -0.221]
PIR R [1.675, 1.675, 1.679, 1.679, 1.679, 1.679, 1.679, 1.683, 1.573, 0.944, 0.451, 0.027, 0.341, -0.576, -0.723, -0.845, -0.886, -0.894, -0.833, -0.784, -0.629, -0.443, -0.295, -0.087, 0]
MR U [-0.185, 0.389, -0.495, -1.338, -1.25, -0.717, -0.043, 0.342, -0.036, -0.34, -0.319, -0.225, -0.124, 0.099, 0.348, 0.888, 1.09, 1.588, 0.881, 0.578, 0.369, 0.24, 0.24, 0.247, 0.119]
PIR U [-2.68, -2.826, -2.877, -2.882, -2.882, -2.897, -2.882, -2.882, -2.897, -2.913, -2.882, -2.882, -2.913, -2.882, -2.887, -2.882, -2.887, -2.882, -2.877, -2.842, -2.644, -2.426, -2.153, -1.94]
MR len [-0.197, -0.838, -0.61, -0.999, -1.139, 0.016, -0.352, -0.312, 0.214, 0.474, 0.457, 0.349, 0.374, 0.506, 0.72, 1.218, 1.418, 1.388, 0.798, -0.067, -0.581, -0.673, -0.353, 0.257, 0.206]
PIR len [-0.063, -0.066, -0.062, -0.064, -0.064, -0.064, -0.064, -0.06, -0.163, -0.882, -1.424, -1.895, -2.298, -2.554, -2.713, -2.844, -2.888, -2.896, -2.831, -2.773, -2.809, -2.396, -2.206, -1.931, -1.786]
MR alpha [0.822, 1.282, 0.632, -0.596, -1.866, -1.993, 0.492, 0.298, -0.22, -0.168, 0.309, 0.622, 0.535, 0.377, 0.189, 0.436, 0.544, 0.519, 0.326, 0.43, 0.469, 0.272, 0.014, -0.521, -0.679]
MR beta [-0.928, -0.807, -0.879, -0.498, 0.874, 1.028, 0.4, 0.123, -0.172, -0.589, -0.955, -1.076, -0.937, -0.683, -0.416, -0.385, -0.394, -0.299, -0.068, 0.111, 0.243, 0.317, 0.275, 0.361, 0.408]
MR gamma [0.145, -1.131, 0.252, 1.054, 0.869, 0.853, -0.128, -0.58, 0.228, 0.682, 0.653, 0.502, 0.41, 0.249, 0.11, -0.151, -0.235, -0.319, -0.403, -0.681, -0.849, -0.755, -0.483, -0.058, 0.053]
PIR alpha [1.864, 1.852, 1.852, 1.868, 1.868, 1.868, 1.868, 1.86, 1.773, 1.646, 1.55, 1.401, 1.27, 1.167, 1.065, 1.026, 1.019, 1.078, 1.075, 1.226, 1.355, 1.431, 1.531, 1.575]
PIR len [3.251, -3.273, -3.278, -3.293, -3.293, -3.293, -3.294, -3.294, -3.286, -3.206, -3.088, -3.0, -2.862, -2.739, -2.643, -2.552, -2.512, -2.506, -2.558, -2.557, -2.689, -2.702, -2.597, -2.429, -2.262]
PIR gamma [2.559, 2.687, 2.731, 2.735, 2.735, 2.735, 2.749, 2.736, 2.734, 2.743, 2.719, 2.748, 2.752, 2.686, 2.677, 2.745, 2.666, 2.679, 2.67, 2.662, 2.596, 2.234, 1.887, 1.564, 1.31]
```



Невронски мрежи со рекурентни и timedistributed слоеви се соодветни за ваков тип на податоци. Во делот со експерименти ќе бидат демонстрирани перформансите при учење од ваков тип податоци.

## Авторегресија

Авторегресивни модели работат со временски серии така што ги користат вредностите од предходните временски чекори за да ги предвидат вредностите во следните чекори. Се покажало дека со авторегресија од конечен ред  $p$  може да се апроксимира било кој модел со голема точност. Во пракса често се среќава користење на првите 4 AP коефициенти. Со слична логика и во овој проект, секоја временска серија може да се преслика во 4 AP коефициенти кои би се користеле како карактеристики.

```
[-0.82754118833412, -1.5417159264531197, -0.8494036803173547,
-0.06235396892090615, 0.6955457531645628, 1.7230828763765929,
0.2801584054831039, -0.3902913486694264, 0.3967583627270222,
0.5060708226431956, 0.017808501684287683, -0.3611413593584468,
-0.2591163967700183, -0.025916482282181682, 0.28744590281084875,
0.28744590281084875, 0.2655834108276141, 0.2801584054831039,
0.18542094022242026, -0.38300385134168147, -0.689078739106967,
-0.5651912845353039, -0.15709143418158977, 0.7028332504923077,
0.8121457104084812]
```

Секвенца

```
[0.11616503891139758, 0.6636080092161616, -0.7544757346127833,
0.2995319119927753, -0.3804778079163662, 0.020384995443562717]
```

AR коефициенти

## Фреквентен домен

Временските секвенци објаснети во предходните делови може да се трансформираат во фреквентен домен со помош на Fast Fourier Transform. Со таа трансформација секвенцата вредности се разложува на компоненти со различни фреквенции од кои е изграден сигналот. FFT е особено популарен во процесирање на сигнали. Секоја временска серија ќе биде трансформирана во секвенца од магнитудите и/или фазите на градбените елементи.

На следната слика е прикажано разложувањето на една временска секвенца до секвенци од магнитудите и фазите. Секоја од добиените листи може да се агрегира и тоа ќе се забележи во некои од експериментите.

### Временска секвенца

```
[-0.82754118833412, -1.5417159264531197, -0.8494036803173547, -0.06235396892090615, 0.6955457531645628, 1.7230828763765929, 0.2801584054831039, -0.3902913486694264, 0.3967583627270222,
0.5060708226431956, 0.017808501684287683, -0.3611413593584468, -0.2591163967700183, -0.025916482282181682, 0.28744590281084875, 0.28744590281084875, 0.2655834108276141, 0.2801584054831039,
0.18542094022242026, -0.38300385134168147, -0.689078739106967, -0.5651912845353039, -0.15709143418158977, 0.7028332504923077, 0.8121457104084812]
```

### Магнитуди:

```
[0.3286125848632738, 2.9189600783988356, 3.1142185520574484, 5.384400990177827, 6.502446491615667, 5.206015552980872, 0.9299273037439519, 2.085050755929162, 2.7646191784148586,
1.183661196728771, 0.49712631550658876, 0.6240357429698427, 0.5840222441890291, 0.5840222441890295, 0.624035742969843, 0.49712631550658876, 1.1836611967287707, 2.7646191784148586,
2.085050755929162, 0.9299273037439517, 5.206015552980872, 6.502446491615667, 5.384400990177827, 3.1142185520574484, 2.9189600783988356]
```

### Фази:

```
[0.0, -2.362521974179, -2.836330249049832, 1.675451268584013, 1.9317643971091405, 1.4445945892021892, -0.950269465906523, 3.0714066064557293, 2.211295452392326, 1.4317380157802293,
-0.3903972859840557, -1.7416146792765825, -3.1244274408110275, 3.124427440811027, 1.741614679276583, 0.3903972859840557, -1.431738015780229, -2.211295452392326, -3.0714066064557293,
0.9502694659065225, -1.4445945892021892, -1.9317643971091405, -1.675451268584013, 2.836330249049832, 2.3625219741789993]
```

FFT се користи за стационарни сигнали на кои не им се менува средната вредност, варијанса и коваријанса со текот на времето. За нестационарни променливи сигнали посоодветни се wavelets кои можат да се справат со сигнали кои имаат испади (bursts).

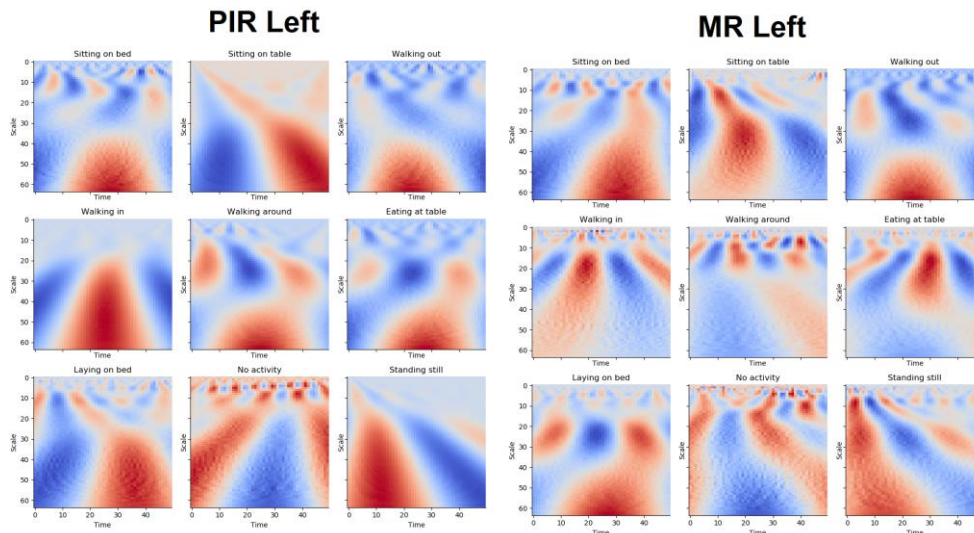
## Wavelets

Додека со FFT сигналот се разложува на синусоидни бранови со различни фреквенции, wavelet анализата го разложува сигналот на поместени (shifted) и скалирани вредности од оригиналниот (mother) вејвлет. Wavelets се математички функции кои за разлика од



FT (синусни функции од  $+\infty$  до  $-\infty$ ) користат различни фамилии и типови вејвлети со различна компактност и измазнување. Тие имаат 0 средна вредност и се временски ограничени. Различните фамилии вејвлети овозможуваат подобро приспособување на текстурите и формите на сигналите. Популарни типови се mexican, morlet и gaussian.

Со вејвлет трансформација временските серии се сведуваат на вејвлет коефициенти. На следната слика се визуелизирани коефициентите за секоја активност за мерењата од МР и ПИР сензорите од левиот модул.



Кога станува збор за трансформација на податоците со continuous wavelet transform (cwt), целта е на излез да се добијат дво-димензионални низи со коефициенти - налик пиксели на слика. Ваквите image-like податоци потоа се особено погодни за учење со конволуциски невронски мрежи.

## Збиен вектор со карактеристики

Повеќето од досега наведените погледи на податоците се засноваат на трансформации кои некакви сигнални мерења - серии ги трансформираат во серии со вредности во различни домени или пак вредности извлечени од изворниот сигнал. Ваквите 2D податоци се користат со невронски мрежи. Сепак, во овој проект е погодно да се експериментира и со класификатори кои примаат на влез поинакви податоци. Тие најчесто ги интегрираат временските серии не како низа вредности туку ги заменуваат со низа пресметани метрики како карактеристики.

Од 14те серии кои ги содржат сензорските мерења (6) и дополнителните пресметки базирани на координатен систем (8) може да се извлечат неколку карактеристики кои на некој начин ги интегрираат временските серии, FFT на сигналите, AR коефициентите како и корелацијата помеѓу сериите.

За секоја серија се пресметуваа:

- средна вредност, стандардна девијација, минимум, максимум, интерквартилен опсег, ентропија, енергија,, првите четири AR коефициенти...
- за серијата се пресметува соодветната fft coefficients серија и од неа се извлекуваат: средна вредност, минимум, максимум, kurtosis, skewness...

Репрезентација за соодносот помеѓу сериите се карактеристиките:

- за пасивен инфрацрвениот сензор: корелација меѓу X и Y, Y и Z, X и Z

- за микробрановиот радар сензор: корелација меѓу X и Y, Y и Z, X и Z
- помеѓу двата типа на сензори: корелација меѓу X и X, Y и Y, Z и Z
- signal magnitude area закој од двата типа сензори
- median absolute deviation закој од двата типа сензори

Финално се добива вектор со карактеристики 258. Во експерименталниот дел се користеа различни комбинации на карактеристиките за да се откријат комбинации кои носат најкорисни информации, а со тоа и најдобри перформанси.

## Експерименти и резултати

Експериментирањето може да се подели на три целини според форматот на податоците и техниките за учење:

- рекурентни и конволуциски невронски мрежи (python - keras module) кои се тренираат на временски серии
- конволуциска невронска мрежа (python - keras module) која е тренирана на матрици од wavelet коефициенти
- различни класификатори од алатката Weka тренирани на комбинации карактеристики од векторот со должина 258


### 1 Невронски мрежи и временски серии

Експериментите користат различни комбинации на архитектури на невронски мрежи, комбинации на временски серии, должини на лизгачки прозорци. Целта на ова е да се увиди која комбинација на параметри ги дава најдобрите резултати. Дополнително, така се добива увид дали оригиналните 6 временски серии се доволни или подобри се перформансите со некои или сите од дополнителните 14. Должината на лизгачките прозорци е променлив параметар бидејќи потребно е да се воочи која должина е најповолна за препознавање на човечка активност. Експериментите се изведуваа за лизгачки прозорци со времетраење 1, 2, 3, 4, 5, 6, 7, 8, 9 и 10 секунди.


### Архитектури на невронски мрежи

Во овој проект се користат повеќе архитектури на невронски мрежи кои се разликуваат според типот, редоследот и параметрите на слоевите. Целта на ова е да се споредат перформансите на различните архитектури кога сите се тренираат на истите податоци. Повеќето се рекурентни невронски мрежи бидејќи таквите се корисни за временски серии. Се користеа LSTM, GRU, simpleRNN, BiLSTM, TimeDistributed (wrapping). Експериментите вклучуваат само една конволуциска невронска мрежа. Во прилог се сликовити репрезентации на мрежите. Секој модел беше подеднакво тестиран, но одредени се истакнаа како најуспешни во класификациите.

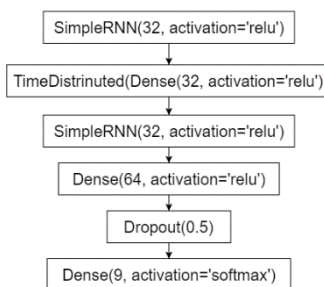
### - Архитектури со simpleRNN слоеви



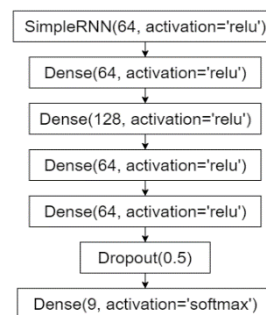
RNN 1



RNN 2

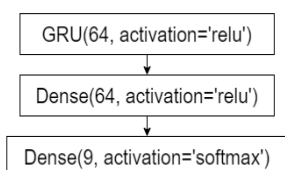


RNN 3




RNN 4


### - Архитектури со GRU слоеви



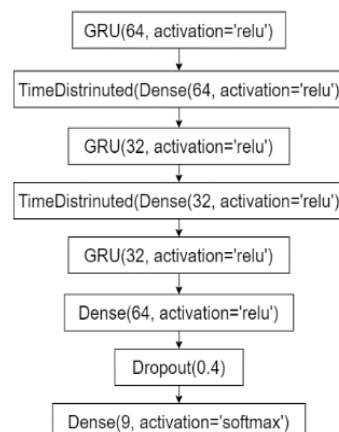
GRU 1



GRU 2




GRU 3




GRU 4


### - Архитектури со LSTM слоеви



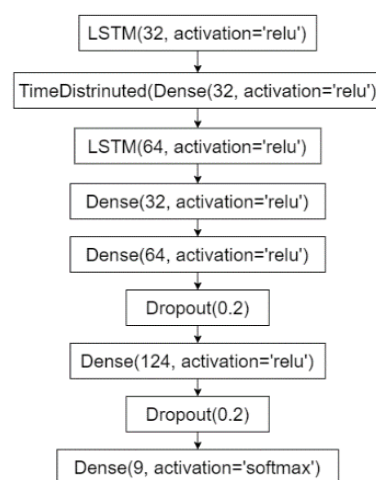
LSTM 1



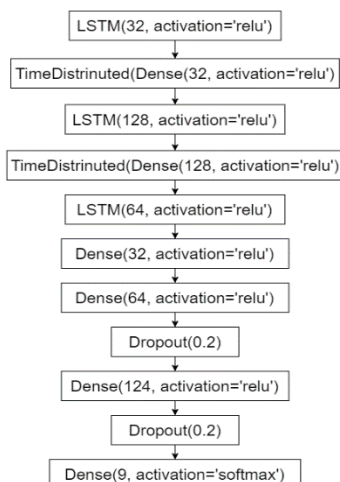
LSTM 2



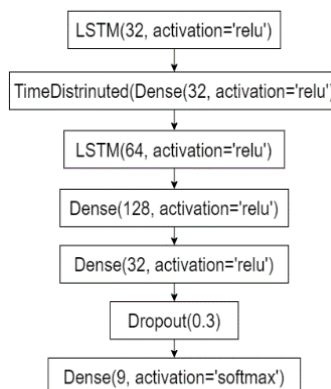
LSTM 3



LSTM TD 1

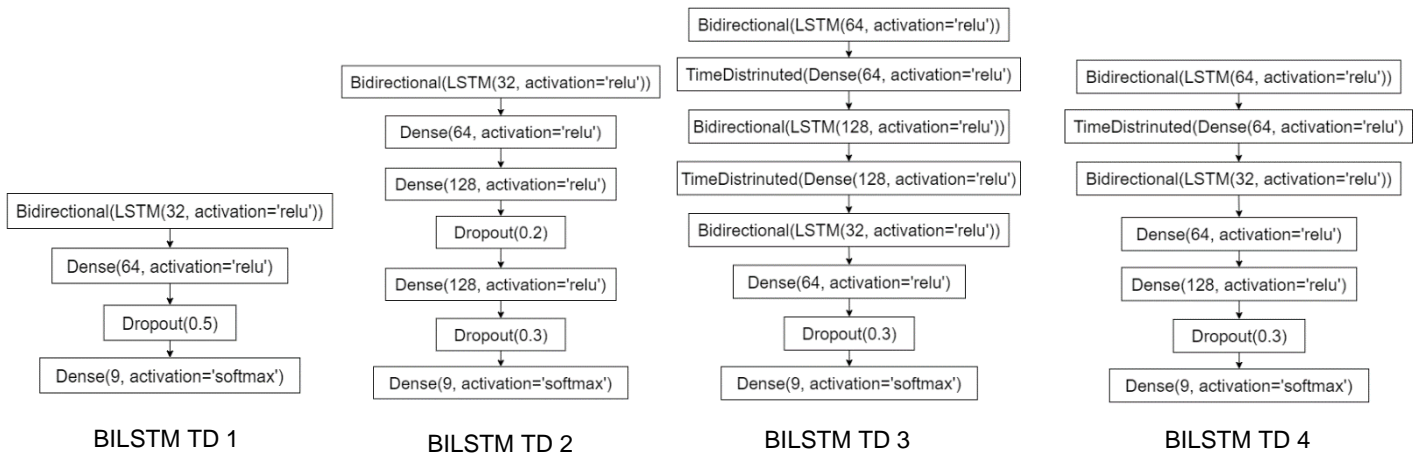


LSTM TD 2

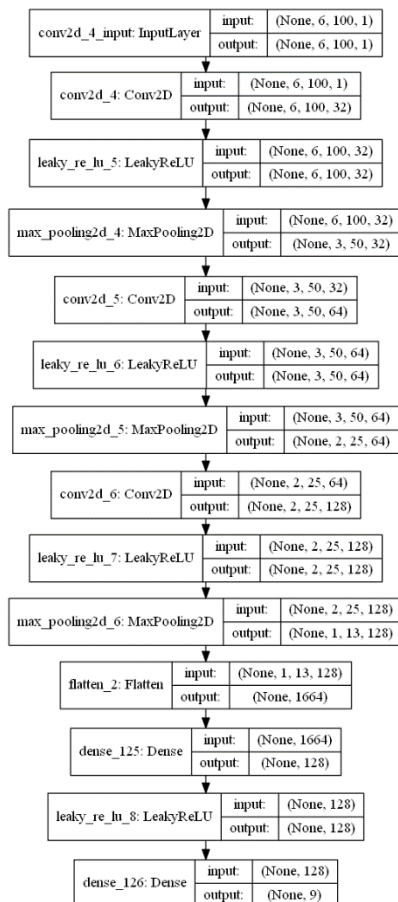


LSTM TD 2

## - Архитектури со двонасочни BiLSTM слоеви



## - Архитектура со конволуциски слој



Conv2D

## Резултати

Перформансите на невронските мрежи се евалуираат според метриките micro average precision, micro average recall, macro average precision, macro average recall, accuracy, f1 averaged. За секоја од метриките ги избрав најдобрите 3 и тие за прикажани во табелата подолу. Здебелени се мерките каде дадениот експеримент дава најдобри (top 3) перформанси.

series	window size	neural network	mac. avg. precision	mac. avg.	ma. avg.	acc	f1
first 6	25	BILSTM_3	<b>0.421</b>	0.329	0.365	<b>0.421</b>	0.335
all but UP	50	Conv2D	<b>0.419</b>	<b>0.353</b>	0.367	<b>0.419</b>	<b>0.354</b>
all 14	50	Conv2D	<b>0.416</b>	0.35	0.353	0.416	0.35
all 14	125	Conv2D	0.412	<b>0.352</b>	0.361	0.412	<b>0.354</b>
all but Right	50	Conv2D	0.416	<b>0.338</b>	0.341	<b>0.416</b>	0.337
first 6	25	LSTM_TD_1	0.403	0.29	<b>0.421</b>	0.403	0.268
all but Left	250	Conv2D	0.366	0.281	<b>0.392</b>	0.366	0.292
all but Right	25	LSTM_TD_1	0.403	0.289	<b>0.379</b>	0.403	0.254
all but left	75	Conv2D	0.384	0.33	0.37	0.384	<b>0.342</b>

Резултатите покажуваат дека невронската мрежа со конволуциски слоеви дава најдобри перформанси во најголем дел од метриките. Користење на првите 6 временски серии има најдобри перформанси во метриките micro average precision, recall и accuracy.

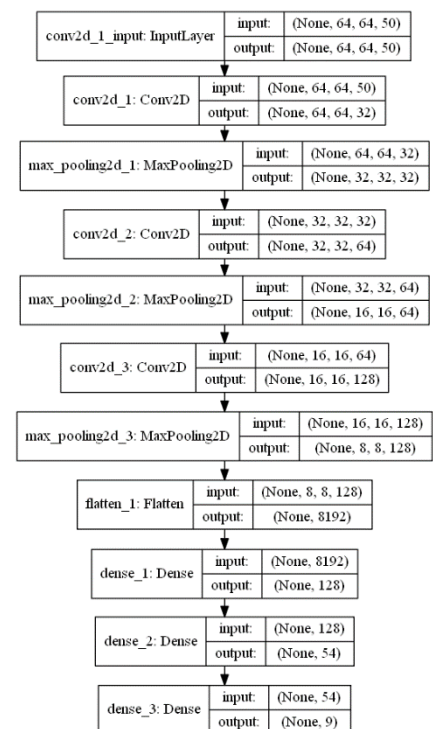
Од резултатите за деталните метрики за секоја класа се забележува конзистентни добри перформанси за истите класи на активности во сите изведени експерименти. Активностите WA, ET и NA во голем дел случаеви покажуваат прецизност од околу 0.6, со максимум од 0.8. Спротивно, инстанците лабелирани со активността SD вообичаено се погрешно препознаени, прецизността речиси секогаш е под 0.1.

## 2 Конволуциска невронска мрежа и wavelet images

Во овие експерименти се користеше конволуциска невронска мрежа бидејќи податоците се налик пиксели на слика и таквата архитектура е најсоодветна. На сликата десно е видлива архитектурата.

Променливите параметри се должината на прозорците и комбинациите на серии. Користени вредности за прозорците се 1, 2, 3, 4, 5 и 6 секунди. Временските серии од кои се извлекуваат wavelet коефициентите се или оригиналните 6 или проширени со дополнителните 8. Резултатите се видливи во табелата во прилог:

series	window size	accuracy %
first 6	25	41.77
first 6	50	38.88
first 6	75	40.17
first 6	100	34.92
all 14	25	40.88
all 14	50	38.74
all 14	75	40.27
all 14	100	37.03



Резултатите покажуваат дека користење на првите 6 серии и прозорци со должина 1 секунда ги даваат најдобрите резултати. Освен ова, високо рангирани се и експериментите кои користат прозорец со должина 3 секунди и само за првите 6 временски серии, а и за сите 14. Класите за кои се измерени најдобри перформанси се : WA, NA и ET. Секако, ова доаѓа со цена, односно натрупување на класификациите во неколку од класите предизвикува многу true positives, но и многу погрешни класификации false positives. Следно се прикажани confusion matrices за најдобрите класификации во експериментите.

Confusion Matrix

Sitting on bed	151	86	42	34	115	64	113	56	42
Sitting on table	68	109	7	12	103	52	68	37	16
Walking out	0	0	1	2	0	0	0	0	0
Walking in	0	0	3	2	0	0	0	0	0
Walking around	303	208	88	84	702	161	257	197	127
Eating at table	76	133	16	17	69	382	54	47	29
Laying on bed	70	65	11	6	64	30	89	55	18
No activity	94	47	5	3	18	17	109	644	6
Standing still	0	0	0	0	1	0	0	0	0
True Label	Sitting on bed	Sitting on table	Walking out	Walking in	Walking around	Eating at table	Laying on bed	No activity	Standing still
	Predicted Label								

Должина на прозорец: 25, серии: 6

Confusion Matrix

Sitting on bed	45	39	19	14	60	29	42	26	19
Sitting on table	42	36	10	9	44	20	28	21	11
Walking out	0	0	0	0	0	0	2	0	0
Walking in	0	0	0	1	0	0	0	0	0
Walking around	83	67	19	20	210	60	72	62	32
Eating at table	19	43	3	6	29	117	16	4	7
Laying on bed	26	22	8	4	28	11	33	10	14
No activity	51	20	3	1	6	11	50	241	1
Standing still	1	0	0	0	0	0	0	0	0
True Label	Sitting on bed	Sitting on table	Walking out	Walking in	Walking around	Eating at table	Laying on bed	No activity	Standing still
	Predicted Label								

Должина на прозорец: 75, серии: 6

Confusion Matrix

Sitting on bed	53	35	6	7	31	15	51	31	14
Sitting on table	26	37	5	1	25	16	23	13	8
Walking out	0	0	2	1	1	0	1	1	0
Walking in	0	2	5	5	2	0	0	0	0
Walking around	97	58	29	20	246	39	63	45	36
Eating at table	18	49	2	3	14	146	9	7	9
Laying on bed	53	39	9	16	45	27	53	31	14
No activity	20	8	4	2	13	5	43	234	3
Standing still	0	0	0	0	0	0	0	1	0
True Label	Sitting on bed	Sitting on table	Walking out	Walking in	Walking around	Eating at table	Laying on bed	No activity	Standing still
	Predicted Label								

Должина на прозорец: 75, серии: 14



### 3 Класификатори од алатката Weka

За експериментите од овој дел се користеа неколку класификатори од алатката WEKA. Неколку аспекти беа променливи за експериментите: самите параметри на класификаторот, поделбата на податочното множество на делови за тренирање и тестирање, големината на лизгачките прозорци во податочното множество и карактеристиките извлечени од прозорците беа филтрирани. Лизгачките прозорци варираат со должина 1, 2, 3, 4 и 5 секунди. Класификаторите кои се користеа се RandomTree, IBk, MultilayerPerceptron, SMO, LibSVM и NaiveBayes.

Во сите експерименти најдобри перформанси даваат податоците каде должината на прозорецот е 3 секунди. Дополнително, 80/20 train/test поделба се покажа подобра од 70/30 поделба на множеството. При обид да се добие намалено множество на карактеристики се воочува дека испуштање на параметрите entropy, energy, maxInds, kurtosis, skewness за сите 14 серии дава 188 карактеристики кои потоа даваат најдобри резултати. Со горенаведените заклучоци, останува да се посочи класификаторот со најдобри перформанси: RandomForest.

Correctly Classified Instances	51.8233 %
Incorrectly Classified Instances	48.1767 %
Kappa statistic	0.4293
Mean absolute error	0.1409
Root mean squared error	0.2591
Relative absolute error	73.9668 %
Root relative squared error	83.9814 %

Судејќи според прецизноста постигната за секоја од класите, највисока е вредноста 1 за класата SD што е сосема спотивно од вооченото од експерименталниот дел 1. Со висока точност се и NA (0.658) и ET (0.636).

Експерименти со приближно добри резултати со истиот класификатор дадоа и податочните множества со лизгачки прозорци со големина 100 и 50 со 48,527% и 49.649% точно класифицирани инстанци соодветно.

## Заклучок

Овој труд е експериментален обид кој ги истражува некои од можностите и начините на кои може да се пристапи на ваков класификациски проблем. Иако не се добиваат резултати со многу добри перформанси споредено со досегашната работа на тоа поле, се обидов да опфатам различни пристапи кон класификација: со невронски мрежи и класификатори, а и различни начини да се интерпретираат сензорските мерења: временски серии, фреквентни компоненти, вејлети, авторегресиски коефициенти и друго.

## Github repository

<https://github.com/djankovik/PR-Project---Experimental-HAR>

## Користена литература

1. <https://www.geeksforgeeks.org/human-activity-recognition-using-deep-learning-model/>
2. <https://www.nature.com/articles/s41467-020-15086-2>
3. <https://www.frontiersin.org/articles/10.3389/frobt.2015.00028/full>
4. <https://machinelearningmastery.com/deep-learning-models-for-human-activity-recognition/>
5. <https://www.sciencedirect.com/science/article/pii/S1877050919310166>
6. <https://onlinelibrary.wiley.com/doi/full/10.4218/etrij.2018-0577>
7. <https://www.nature.com/articles/s41467-020-15086-2/f>
8. <https://archive.ics.uci.edu/ml/datasets/human+activity+recognition+using+smartphones>
9. <https://archive.ics.uci.edu/ml/datasets/Smartphone+Dataset+for+Human+Activity+Recognition+%28HAR%29+in+Ambient+Assisted+Living+%28AAL%29>
10. <https://www.mdpi.com/1424-8220/19/17/3710/htm>
11. <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6749575/>
12. <https://machinelearningmastery.com/cnn-models-for-human-activity-recognition-time-series-classification/>
13. <https://ieeexplore.ieee.org/document/7026300>
14. <https://www.sciencedirect.com/science/article/abs/pii/S016786551830045X>
15. <https://www.dropbox.com/s/4l1mqwthcpx38fa/%5BICMLC%202008%5D%20Activity%20recognition%20from%20acceleration%20data%20using%20AR%20model%20representation%20and%20SVM.pdf?dl=0>
16. <https://machinelearningmastery.com/autoregression-models-time-series-forecasting-python/>
17. <https://towardsdatascience.com/how-and-why-to-standardize-your-data-996926c2c832>
18. <https://pywavelets.readthedocs.io/en/0.2.2/>
19. <https://towardsdatascience.com/recurrent-neural-networks-by-example-in-python-ffd204f99470>
20. [https://subscription.packtpub.com/book/big\\_data\\_and\\_business\\_intelligence/9781787125193/4/ch04/v1/sec35/adding-long-short-term-memory-lstm](https://subscription.packtpub.com/book/big_data_and_business_intelligence/9781787125193/4/ch04/v1/sec35/adding-long-short-term-memory-lstm)